HOMEWORK 6: TEXT CLASSIFICATION

In this homework, you will create models to classify texts from TRUE call-center. There are two classification tasks:

- 1. Action Classification: Identify which action the customer would like to take (e.g. enquire, report, cancle)
- 2. Object Classification: Identify which object the customer is referring to (e.g. payment, truemoney, internet, roaming)

We will focus only on the Object Classification task for this homework.

In this homework, you are asked compare different text classification models in terms of accuracy and inference time.

You will need to build 3 different models.

- 1. A model based on tf-idf
- 2. A model based on MUSE
- 3. A model based on wangchanBERTa

You will be ask to submit 3 different files (.pdf from .ipynb) that does the 3 different models. Finally, answer the accuracy and runtime numbers in MCV.

This homework is quite free form, and your answer may vary. We hope that the processing during the course of this assignment will make you think more about the design choices in text classification.

In [1]: !wget --no-check-certificate https://www.dropbox.com/s/37u83g55p19kvrl/clean-pho

```
--2025-02-16 14:31:25-- https://www.dropbox.com/s/37u83g55p19kvrl/clean-phone-da
       ta-for-students.csv
       Resolving www.dropbox.com (www.dropbox.com)... 162.125.1.18, 2620:100:6016:18::a2
       7d:112
       Connecting to www.dropbox.com (www.dropbox.com)|162.125.1.18|:443... connected.
       HTTP request sent, awaiting response... 302 Found
       Location: https://www.dropbox.com/scl/fi/8h8hvsw9uj6o0524lfe4i/clean-phone-data-f
       or-students.csv?rlkey=lwv5xbf16jerehnv3lfgq5ue6 [following]
       --2025-02-16 14:31:25-- https://www.dropbox.com/scl/fi/8h8hvsw9uj6o0524lfe4i/cle
       an-phone-data-for-students.csv?rlkey=lwv5xbf16jerehnv3lfgq5ue6
       Reusing existing connection to www.dropbox.com:443.
       HTTP request sent, awaiting response... 302 Found
       Location: https://uce9b4d9ce07540704f730162084.dl.dropboxusercontent.com/cd/0/inl
       ine/CkNwY6dA0mIUMFAmX-HKzPI5krHfWCSD1PL4FmlWgrPqx-9wx0E1E0YeYbzGwZxsq54tbI1550tjn
       CAqKzphbFIpKUyLGINc8t5FPYeeCrdtalrPlTbDFuEmG5BT2KPOlb8/file# [following]
       --2025-02-16 14:31:25-- https://uce9b4d9ce07540704f730162084.dl.dropboxuserconte
       nt.com/cd/0/inline/CkNwY6dA0mIUMFAmX-HKzPI5krHfWCSD1PL4FmlWgrPqx-9wx0E1EOYeYbzGwZ
       xsq54tbI1550tjnCAqKzphbFIpKUyLGINc8t5FPYeeCrdtalrPlTbDFuEmG5BT2KPOlb8/file
       Resolving uce9b4d9ce07540704f730162084.dl.dropboxusercontent.com (uce9b4d9ce07540
       704f730162084.dl.dropboxusercontent.com)... 162.125.1.15, 2620:100:6016:15::a27d:
       10f
       Connecting to uce9b4d9ce07540704f730162084.dl.dropboxusercontent.com (uce9b4d9ce0
       7540704f730162084.dl.dropboxusercontent.com) | 162.125.1.15 | :443... connected.
       HTTP request sent, awaiting response... 200 OK
       Length: 2518977 (2.4M) [text/plain]
       Saving to: 'clean-phone-data-for-students.csv'
       clean-phone-data-fo 100%[========>] 2.40M --.-KB/s
                                                                           in 0.04s
       2025-02-16 14:31:26 (54.9 MB/s) - 'clean-phone-data-for-students.csv' saved [2518
       977/2518977]
In [2]: !pip install pythainlp
       Collecting pythainlp
         Downloading pythainlp-5.0.5-py3-none-any.whl.metadata (7.5 kB)
       Requirement already satisfied: requests>=2.22.0 in /usr/local/lib/python3.10/dist
       -packages (from pythainlp) (2.32.3)
       Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python
       3.10/dist-packages (from requests>=2.22.0->pythainlp) (3.4.1)
       Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-pac
       kages (from requests>=2.22.0->pythainlp) (3.10)
       Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/di
       st-packages (from requests>=2.22.0->pythainlp) (2.3.0)
       Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/di
       st-packages (from requests>=2.22.0->pythainlp) (2025.1.31)
       Downloading pythainlp-5.0.5-py3-none-any.whl (17.9 MB)
                                                 - 17.9/17.9 MB 84.4 MB/s eta 0:00:00:0
       0:0100:01
       Installing collected packages: pythainlp
       Successfully installed pythainlp-5.0.5
```

Import Libs

In [3]: %matplotlib inline import pandas import sklearn import numpy as np

```
import matplotlib.pyplot as plt
import pandas as pd

from torch.utils.data import Dataset
from IPython.display import display
from collections import defaultdict
from sklearn.metrics import accuracy_score
from sklearn.model_selection import train_test_split
from pythainlp.tokenize import word_tokenize
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline
from pythainlp.corpus.common import thai_stopwords
import time
```

Loading data

First, we load the data from disk into a Dataframe.

A Dataframe is essentially a table, or 2D-array/Matrix with a name for each column.

```
In [4]: data_df = pd.read_csv('clean-phone-data-for-students.csv')
```

Let's preview the data.

```
In [5]: # Show the top 5 rows
display(data_df.head())
# Summarize the data
data_df.describe()
```

Object	Action	Sentence Utterance	
payment	enquire	<phone_number_removed> ผมไปจ่ายเงินที่ Counte</phone_number_removed>	0
package	enquire	internet ยังความเร็วอยุ่เท่าไหร ครับ	1
suspend	report	ตะกี้ไปชำระค่าบริการไปแล้ว แต่ยังใช้งานไม่ได้	2
internet	enquire	พี่ค่ะยังใช้ internet ไม่ได้เลยค่ะ เป็นเครื่อ	3
phone_issues	report	ฮาโหล คะ พอดีว่าเมื่อวานเปิดซิมทรูมูฟ แต่มันโ	4

 Out[5]:
 Sentence Utterance
 Action
 Object

 count
 16175
 16175
 16175

 unique
 13389
 10
 33

 top
 บริการอื่นๆ
 enquire
 service

97

10377

Data cleaning

freq

We call the DataFrame.describe() again. Notice that there are 33 unique labels/classes for object and 10 unique labels for action that the model will try to predict. But there are

2525

unwanted duplications e.g. Idd,idd,lotalty_card,Lotalty_card

Also note that, there are 13389 unquie sentence utterances from 16175 utterances. You have to clean that too!

#TODO 0.1:

In [7]: data df.columns

You will have to remove unwanted label duplications as well as duplications in text inputs. Also, you will have to trim out unwanted whitespaces from the text inputs. This shouldn't be too hard, as you have already seen it in the demo.

```
In [6]: display(data_df.describe())
    display(data_df.Object.unique())
    display(data_df.Action.unique())
```

```
Count161751617516175unique133891033topบริการอื่นๆenquireservicefreq97103772525
```

Out[7]: Index(['Sentence Utterance', 'Action', 'Object'], dtype='object')

```
In [8]:
    start = time.time()
    cols = ["Sentence Utterance", "Object"]
    data_df = data_df[cols]
    data_df.columns = ["input", "raw_label"]

    data_df["clean_label"]=data_df["raw_label"].str.lower().copy()
    data_df.drop("raw_label", axis=1, inplace=True)

    data_df["input"] = data_df["input"].str.strip()

    data_df = data_df.drop_duplicates(subset=['input'], keep='first')
```

```
In [9]: display(data_df["clean_label"].unique())
    display(data_df.describe())
    display(data_df.head())
```

	input	clean_label
count	13367	13367
unique	13367	26
top	สอบถามโปรโมชั่นปัจจุบันที่ใช้อยู่ค่ะ	service
freq	1	2108

	input	clean_label
0	<phone_number_removed> ผมไปจ่ายเงินที่ Counter</phone_number_removed>	payment
1	internet ยังความเร็วอยุ่เท่าไหร ครับ	package
2	ตะกี้ไปชำระค่าบริการไปแล้ว แต่ยังใช้งานไม่ได้ ค่ะ	suspend
3	พี่ค่ะยังใช้ internet ไม่ได้เลยค่ะ เป็นเครื่อง	internet
4	ฮาโหล คะ พอดีว่าเมื่อวานเปิดซิมทรูมูฟ แต่มันโท	phone_issues

Split data into train, valdation, and test sets (normally the ratio will be 80:10:10, respectively). We recommend to use train_test_spilt from scikit-learn to split the data into train, validation, test set.

In addition, it should split the data that distribution of the labels in train, validation, test set are similar. There is **stratify** option to handle this issue.

https://scikit-

learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html

Make sure the same data splitting is used for all models.

```
In [10]: data_x = np.array(list(data_df["input"]))
    data_y_tmp = np.array(list(data_df["clean_label"]))
    data_y = []

map_label_num = {y.strip():i for i,y in enumerate(list(data_df["clean_label"].un
    map_num_label = {i:y.strip() for i,y in enumerate(list(data_df["clean_label"].un

    for i in range(len(data_y_tmp)):
        data_y.append(int(map_label_num[data_y_tmp[i]]))
    data_y = np.array(data_y)
    print(len(data_y))
```

13367

```
In [11]: unique, counts = np.unique(data_y, return_counts=True)
   valid_classes = unique[counts >= 10]
   valid_indices = np.isin(data_y, valid_classes)
   data_x,data_y = data_x[valid_indices],data_y[valid_indices]
```

```
In [12]: X_train, X_temp, y_train, y_temp = train_test_split(data_x, data_y, test_size=0.
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size=0.50,

print("Train size:", len(X_train))
print("Validation size:", len(X_val))
print("Test size:",len(X_test))
```

Train size: 10690 Validation size: 1336 Test size: 1337

Model 1 TF-IDF

Build a model to train a tf-idf text classifier. Use a simple logistic regression model for the classifier.

For this part, you may find this tutorial helpful.

Below are some design choices you need to consider to accomplish this task. Be sure to answer them when you submit your model.

What tokenizer will you use? Why?

Ans:

Will you ignore some stop words (a, an, the, to, etc. for English) in your tf-idf? Is it important? PythaiNLP provides a list of stopwords if you want to use (https://pythainlp.org/docs/2.0/api/corpus.html#pythainlp.corpus.common.thai_stopwords)

Ans:

The dictionary of TF-IDF is usually based on the training data. How many words in the test set are OOVs?

Ans:

```
In [13]:    def thai_tokenizer(text):
        return word_tokenize(text, keep_whitespace=False)

In [14]:    from sklearn.feature_extraction.text import TfidfVectorizer
    from sklearn.linear_model import LogisticRegression
    from sklearn.pipeline import Pipeline
    from pythainlp.corpus.common import thai_stopwords
    import numpy as np
    import time

# Define stopwords
stopwords = list(thai_stopwords())

# Initialize TF-IDF Vectorizer
vectorizer = TfidfVectorizer(
    tokenizer=None, # Use default tokenization
    stop_words=stopwords, # Remove Thai stopwords
    max_features=10000 # Limit vocabulary size to avoid overfitting
```

```
# Create a logistic regression pipeline
model = Pipeline([
    ("tfidf", vectorizer),
    ("classifier", LogisticRegression(max_iter=1000, random_state=42))
])
# Train model
start = time.time()
model.fit(X_train, y_train)
end = time.time()
# Evaluate model
print(f"Training time: {end - start:.4f} seconds")
train_acc = model.score(X_train, y_train)
val_acc = model.score(X_val, y_val)
test_acc = model.score(X_test, y_test)
print(f"Train Accuracy: {train_acc:.4f}")
print(f"Validation Accuracy: {val_acc:.4f}")
print(f"Test Accuracy: {test_acc:.4f}")
# Check OOV words (words in test set not seen in train set)
train_vocab = set(vectorizer.get_feature_names_out())
test_vocab = set(word for sentence in X_test for word in sentence.split())
oov_words = test_vocab - train_vocab
print(f"Number of OOV words: {len(oov_words)}")
```

/usr/local/lib/python3.10/dist-packages/sklearn/feature_extraction/text.py:409: U serWarning: Your stop_words may be inconsistent with your preprocessing. Tokenizi ng the stop words generated tokens ['กคน', 'กคร', 'กครา', 'กคราว', 'กจะ', 'กช', 'กต', 'กท', 'กทาง', 'กน', 'กระท', 'กระน', 'กระไร', 'กล', 'กว', 'กส', 'กห์น', 'ก อ', 'กอย', 'กำล', 'กเม', 'กแห', 'กๆ', 'ขณะท', 'ขณะน', 'ขณะหน', 'ขณะเด', 'คงอ ย', 'คร', 'ครบคร', 'ครบถ', 'คราท', 'คราน', 'คราวก', 'คราวท', 'คราวน', 'คราวหน', ่ คราวหล่, 'คราวโน', 'คราหน', 'คล', 'งก', 'งกระน', 'งกล', 'งกว', 'งข', 'งคง', 'งค น', 'งครา', 'งคราว', 'งง', 'งจ', 'งจน', 'งจะ', 'งจาก', 'งต', 'งท', 'งน', 'งบ', 'งป ้วง', 'งมวล', 'งละ', 'งว', 'งส', 'งหน', 'งหมด', 'งหมาย', 'งหล', 'งหลาย', 'งอย', , 'งเคย', 'งเน', 'งเป', 'งเม', 'งแก', 'งแต', 'งแม', 'งแล', 'งโง', 'งโน', 'งใ ด', 'งใหญ', 'งไง', 'งได', 'งไหน', 'งๆ', ่งๆจ', ่จก', 'จจ', 'จนกระท', 'จนกว', 'จน ขณะน', 'จนถ', 'จนท', 'จนบ', 'จนเม', 'จนแม', 'จร', 'จรดก', 'จวนเจ', 'จวบก', 'จส', 'จสมบ', 'จะได', 'จากน', 'จำเป', 'จแล', 'ฉะน', 'ซะก', 'ซะจนกระท', 'ซะจนถ', 'ณๆ', 'ดการ', 'ดงาน', 'ดดล', 'ดต', 'ดทำ', 'ดน', 'ดว', 'ดหน', 'ดหา', 'ดเด', 'ดเผย', 'ด แจง', 'ดให', 'ดไป', 'ดๆ', 'ตลอดถ', 'ตลอดท', 'ตลอดป', 'ตลอดว', 'ตามด', 'ตามท', ี่ตามแต่', 'ทว', 'ทำให่', 'นก', 'นการ', 'นกาลนาน', 'นควร', 'นจะ', 'นด', 'นต', 'น ท', 'นน', 'นนะ', 'นนาน', 'นมา', 'นมาก', 'นย', 'นยง', 'นยาว', 'นละ', 'นว', 'นวา น', 'นอ', 'นอกจากท', 'นอกจากน', 'นอกจากว', 'นอกน', 'นอกเหน', 'นอาท', 'นา', 'นเค ย', 'นเด', 'นเถอะ', 'นเน', 'นเป', 'นเพ', 'นเพราะ', 'นเพราะว', 'นเม', 'นเอง', 'นแก', 'นแต', 'นและก', 'นแหละ', 'นใด', 'นใดน', 'นไง', 'นได', 'นไป', 'นไร', 'นไว', 'นไห น', 'นไหม', 'นๆ', 'บจากน', 'บต', 'บรอง', 'บว', 'บอกว', 'บอกแล', 'บางกว', 'บางค ร', 'บางท', 'บางแห', 'บเน', 'บแต', 'ปฏ', 'ปร', 'ประการฉะน', 'ประการหน', 'ปรากฏว', 'พบว', 'พร', 'พวกก', 'พวกค', 'พวกฉ', 'พวกท', 'พวกน', 'พวกม', 'พวกโน', 'พอก', 'พอด', 'พอต', 'พอท', 'พอเพ', 'พอแล', 'ภายภาคหน', 'ภายหน', 'ภายหล', 'ภายใต', 'มก', 'มองว', 'มากกว', 'มเต', 'มไปด', 'มไปหมด', 'มๆ', 'ยกให', 'ยง', 'ยงพอ', 'ยง ่ว', 'ยงเพ', 'ยงเพราะ', 'ยงแค', 'ยงแต', 'ยงใด', 'ยงไร', 'ยงไหน', 'ยจน', 'ยจนกระท', ียจนถ', 'ยด', 'ยน', 'ยนะ', 'ยนแปลง', 'ยบ', 'ยย', 'ยล', 'ยว', 'ยวก', 'ยวข', 'ยว น', 'ยวเน', 'ยวๆ', 'ยอมร', 'ยเน', 'ยเอง', 'ยแล', 'ยโน', 'รณ', 'รวดเร', 'รวมก', 'รว มด์', 'รวมถ์', 'รวมท์', 'ระห์ว', 'วก์', 'วง', 'วงก', ่'วงต', ่'วงถ', ่'วงท', ่'วงน', '้วงระห ว', 'วงหน', 'วงหล', 'วงแรก', 'วงๆ', 'วถ', 'วท', 'วน', 'วนจน', 'วนด', 'วนท', 'วน น', 'วนมาก', 'วนเก', 'วนแต', 'วนใด', 'วนใหญ', 'วม', 'วมก', 'วมด', 'วมม', 'วย', ่ 'วยก', 'วยท', 'วยประการฉะน', 'วยว', 'วยเช', 'วยเพราะ', 'วยเหต', 'วยเหม', 'วเสร', 'ว แต', 'วๆ', 'สม', 'สำค', 'หมดก', 'หมดส', 'หร', 'หล', 'หากว', 'หากแม', 'หาร', 'หา ใช', 'อก', 'อค', 'อคร', 'อคราว', 'อคราวก', 'อคราวท', 'อง', 'องจาก', 'องมาจาก', 'อ จะ', 'อจาก', 'อด', 'อถ', 'อท', 'อน', 'อนก', 'อนข', 'อนมาทาง', 'อนว', 'อนหน', ่ 'อนๆ', 'อบ', 'อบจะ', 'อบๆ', 'อม', 'อมก', 'อมด', 'อมท', 'อมเพ', 'อย', 'อยกว', 'อ ยคร', 'อยจะ', 'อยเป', 'อยไปทาง', 'อยๆ', 'อว', 'อวาน', 'อาจเป', 'อเก', 'อเช', 'อเป ล', 'อเม', 'อเย', 'อใด', 'อให', 'อไง', 'อไป', 'อไม', 'อไร', 'อไหร', 'าก', 'าง', 'างก', 'างขวาง', 'างจะ', 'างด', 'างต', 'างท', 'างน', 'างบน', 'างมาก', 'างย', 'าง ล', 'างละ', 'างหน', 'างหาก', 'างเค', 'างเช', 'างเด', 'างโน', 'างใด', 'างไร', 'างไร ก', 'างไรเส', 'างไหน', 'างๆ', 'าจะ', 'าท', 'าน', 'านาน', 'านๆ', 'าพเจ', 'าย', 'าย ก', 'ายว', 'ายใด', 'ายๆ', 'าว', 'าวค', 'าส', 'าหร', 'าหาก', 'าฯ', 'าใจ', 'าใด', 'าใ ห', 'าไร', 'าไหร', 'าๆ', 'เก', 'เข', 'เฉกเช', 'เช', 'เด', 'เต', 'เถ', 'เท', 'เน', 'เ ป', 'เปล', 'เผ', 'เพ', 'เพราะฉะน', 'เพราะว', 'เม', 'เร', 'เล', 'เส', 'เสม', 'เสร', 'เ ห', 'เหต', 'เหล', 'เอ', 'แค', 'แด', 'แท', 'แน', 'แม', 'แล', 'แสดงว', 'แ ห', 'แหล', 'ใกล', 'ใช', 'ใด', 'ใต', 'ในช', 'ในท', 'ในระหว', 'ในเม', 'ให', 'ใหญ', 'ใหม', 'ไบ', 'ได', 'ไม', 'ไว', 'ไหม'] not in stop_words. warnings.warn(

Training time: 5.1646 seconds Train Accuracy: 0.7709 Validation Accuracy: 0.6235

Test Accuracy: 0.6335 Number of OOV words: 2798

In [15]: from sklearn.feature_extraction.text import TfidfVectorizer
 from sklearn.linear_model import LogisticRegression
 from sklearn.pipeline import Pipeline
 from pythainlp.corpus.common import thai_stopwords
 import numpy as np
 import time

```
# Define stopwords
 stopwords = list(thai_stopwords())
 # Initialize TF-IDF Vectorizer
 vectorizer = TfidfVectorizer(
     tokenizer=thai_tokenizer, # Use default tokenization
     stop_words=stopwords, # Remove Thai stopwords
     max_features=10000 # Limit vocabulary size to avoid overfitting
 # Create a logistic regression pipeline
 model = Pipeline([
      ("tfidf", vectorizer),
      ("classifier", LogisticRegression(max_iter=1000, random_state=42))
 ])
 # Train model
 model.fit(X_train, y_train)
 end = time.time()
 # Evaluate model
 train_acc = model.score(X_train, y_train)
 val_acc = model.score(X_val, y_val)
 test_acc = model.score(X_test, y_test)
 print(f"Training time: {end - start:.4f} seconds")
 print(f"Train Accuracy: {train_acc:.4f}")
 print(f"Validation Accuracy: {val_acc:.4f}")
 print(f"Test Accuracy: {test_acc:.4f}")
 # Check OOV words (words in test set not seen in train set)
 train_vocab = set(vectorizer.get_feature_names_out())
 test_vocab = set(word for sentence in X_test for word in sentence.split())
 oov_words = test_vocab - train_vocab
 print(f"Number of OOV words: {len(oov words)}")
/usr/local/lib/python3.10/dist-packages/sklearn/feature_extraction/text.py:528: U
serWarning: The parameter 'token_pattern' will not be used since 'tokenizer' is n
ot None'
  warnings.warn(
/usr/local/lib/python3.10/dist-packages/sklearn/feature_extraction/text.py:409: U
serWarning: Your stop_words may be inconsistent with your preprocessing. Tokenizi
ng the stop words generated tokens ['กระไร', 'กาลนาน', 'ชิ้น', 'ดังที่', 'ดี้', 'ดีกว่า',
'ด้อย', 'ตัว', 'ต่อไป', 'ถัดไป', 'ทั่วถึง', 'ทำ', 'ที่จะ', 'ท่าน', 'ท้าย', 'นา', 'บอ', 'บั
ด', 'ระยะเวลา', ู'ลู่ะ', 'วันวาน', 'สม', 'สมบูรณ์', 'สำ', 'หน้า', 'หรับ', 'หา', 'อย', 'เกี่
ียว', 'เก่า', 'เดี๋ยวนี้', 'เย็น', 'เล่า', 'เสมือน', 'เหมือนกัน', 'แด่', 'แม้น', 'แหล่', 'โง้น',
'โน้น', 'ใด', 'ไว', 'ไหม', '\ufeff'] not in stop_words.
 warnings.warn(
Training time: 8.4621 seconds
Train Accuracy: 0.7650
Validation Accuracy: 0.6939
Test Accuracy: 0.6971
Number of OOV words: 2694
 1. What tokenizer will you use? Why?
```

Ans: pythainlp.word_tokenize เพราะ เชื่อ ว่าออกแบบมาเพื่อภาษาไทยโดยเฉพาะ ดังที่เห็น ว่าaccuracy ของ validation,test สูงกว่า 2.Will you ignore some stop words (a, an, the, to, etc. for English) in your tf-idf? Is it important? PythaiNLP provides a list of stopwords if you want to use (https://pythainlp.org/docs/2.0/api/corpus.html#pythainlp.corpus.common.thai_stopwords)

Ans: ใช่ ใช้pythainlp.thai_stopwords() เพราะมันเป็นคำที่ไม่สื่อความหมายอะไรอยู่แล้ว

3. The dictionary of TF-IDF is usually based on the training data. How many words in the test set are OOVs?

Ans: 2694